

HiCardi 측정 기기를 활용한 개인 ECG 데이터 기반 시계열 패턴 분석

Analyze time series patterns based on personal ECG data with HiCardi measurement devices

의료인공지능학과 22619027 지정원

Abstract: 본 연구는 HiCardi 심전도 측정 기기를 직접 착용하여 수집한 개인 심전도 데이터를 바탕으로, 정상 심전도 신호의 시계열적 특성을 분석하였다. 수집된 데이터는 npy 형식으로 저장되었으며, 이를 불러와 시각화 및 R-peak 기반 분석을 수행한 후, LSTM(Long Short-Term Memory) 기반의 딥러닝 모델에 입력하여 다음 시점의 전압 값을 예측하는 실험을 진행하였다. 이 과정에서 심박수 변화 추세 및 이상 구간 탐지를 병행하여, 정상 심전도의 구조적 특징과 시계열 패턴을 효과적으로 학습할 수 있음을 확인하였다. 본 연구는 질환 예측이나 분류보다는 정상 생체 신호의 표현 학습과 이상 탐지 가능성에 중점을 둔 기초 연구로, 향후 개인 맞춤형 심장 건강 모니터링 시스템 개발의 기반이 될 수 있다는 점에서 의의를 가진다.

Keyword: 심전도, LSTM, 시계열 데이터, HiCardi, 딥러닝

I. 배경

심전도(Electrocardiogram, ECG)는 심장의 전기적 활동을 시계열 신호로 기록한 데이터로, 심혈관 질환을 조기 진단하고 상태를 모니터링 하는 데 있어 가장 핵심적인 생체 신호 중 하나이다. 부정맥, 심근경색, 심부전 등은 ECG 파형에서 나타나는 특징적인 변화를 통해 감지할 수 있으며, 이는 환자의 생명을 구하는 데 중요한 역할을 한다.

기존 병원 중심의 ECG 검사는 일정 시간 동안만 측정이 이루어지기 때문에, 일상생활 중 불규칙하게 발생하는 부정맥이나 이상 신호를 놓칠 가능성이 존재한다. 이에 따라, 휴대용 ECG 기기를 활용한 개인 맞춤형 실시간 모니터링의 필요성이 점차 증가하고 있다.

본 연구에서는 HiCardi 개인용 ECG 기기를 통해 수집한 실제 데이터를 기반으로, 정상 심전도 신호의 구조와 시계열 패턴을 분석하고, 딥러닝 모델이 이를 어떻게 학습하고 예측할 수 있는지를 탐색하였다. 이러한 분석은 향후 부정맥 탐지 또는 이상 징후 감지와 같은 실시간 건강 모니터링 기술로 확장될 수 있는 가능성을 내포하고 있다.

II. 방법

2.1 데이터 수집 및 개요

본 연구에서 활용된 ECG 데이터는 HiCardi 측정 기기를 직접 착용하여 일상생활 중 수집한 개인 생체 신호이

다. HiCardi는 소형의 웨어러블 장비로, 500Hz의 샘플링 주파수를 기반으로 심전도 파형을 장시간 지속적으로 기록할 수 있는 장점이 있다.

수집된 데이터는 npy 형식으로 저장되었으며, 본 실험에서는 약 10,000개의 시계열 샘플을 포함하는 20초 분량의 데이터를 분석에 사용하였다. 분석 대상은 Lead II 유도 기반 단일 채널 ECG이며, 데이터는 μV 단위의 전기적 활동을 나타낸다.

2.2 전처리 과정

2.2.1 신호 로딩 및 기본 정보 추출

수집된 심전도 데이터는 npy 파일 형식으로 불러온 후, 총 샘플 수(N)와 샘플링 주파수($fs = 500Hz$)를 기준으로 전체 측정 시간(초)을 계산하였다. 데이터는 ADC(digital) 값 단위의 전기 신호로 구성되어 있으며, ± 4000 범위 내의 진폭 변화를 보였다. 이를 기반으로 원시 ECG 파형을 시각화하여 신호 품질 및 주요 파형 구조(P파, QRS파, T파 등)를 확인하였고, 이어서 일정 시간 구간(10초 단위)으로 분할하여 평균 심박수(BPM)를 추정한 후, 이를 시계열 그래프로 표현하였다.

본 연구에서는 원본 파형을 단순히 로딩하는 데 그치지 않고, 이를 바탕으로 시간 축과 신호 크기 축의 의미를 해석하고 새로운 형태의 정보(심박수 변화, 이상 탐지 등)로 확장하여 분석하였다.

2.2.2 R-peak 검출

심박의 기준으로 활용되는 R-peak는 일반적으로

ECG 파형에서 가장 뚜렷하게 나타나는 피크로, 이를 감지하기 위해 find peak 함수를 활용하였다.

본 연구에서는 단순한 규칙 기반 검출 방법을 적용하였으며, 피크 높이가 $50\mu V$ 이상 ($height \geq 50$), 연속된 피크 간 최소 간격이 0.5초 이상 ($distance \geq 250$) 두 가지 조건을 만족하는 피크를 R-peak로 간주하였다.

이를 바탕으로 각 구간의 심박수를 추정하였고, 이 방식을 사용하면 복잡한 생체 신호 분석 라이브러리 없이도 비교적 단순한 파형의 심박 구조를 감지할 수 있다.

2.2.3 이상 구간 탐지

R-peak 검출을 기반으로 각 심장 박동 사이의 간격(RR 간격)을 계산하고, 이를 통해 심박수를 추정했다. 이후 전체 데이터를 10초 단위의 슬라이딩 윈도우로 분할하여 각 구간의 평균 심박수를 산출했다. 이렇게 얻은 값들의 평균과 표준편차를 계산한 후, 평균 심박수가 전체 평균에서 ± 2 표준편차를 벗어나는 구간을 이상 구간으로 정의했다.

이 방법은 ECG 장시간 분석에서 흔히 사용되는 통계 기반 이상 탐지 기법으로, 특정 구간에서 심박의 불규칙성이 발생하거나 급격한 박동수 변화가 있을 때 이를 자동으로 감지할 수 있다. 결과적으로 이상 구간은 시각화된 심박수 그래프에서 붉은 점으로 표시되어, 전체 데이터 흐름에서 특이한 구간을 쉽게 식별할 수 있었다.

2.3. 시각화 및 신호 해석

수집된 ECG 데이터에 대한 분석을 더욱 직관적으로 이해하고 해석하기 위해 두 종류의 시각화를 수행하였다.




그림 1. ECG 원시 파형 그래프

[그림 1]은 원시 ECG 파형을 시각화한 것으로, 시간 축을 기준으로 심장의 전기적 활동(ADC 값 기준)을 연속적으로 나타낸다. 이 그래프에서는 P파, QRS 복합파, T파 등의 주요 심전도 구성 요소가 반복적으로 관찰되며, 신호의 품질과 잡음 여부, 파형의 규칙성 등을 육안으로 확인할 수 있다.

해당 그래프는 데이터의 전처리 전 상태를 직관적으로 파악하고, 분석할 수 있는 신호 구조를 갖추고 있는지 확

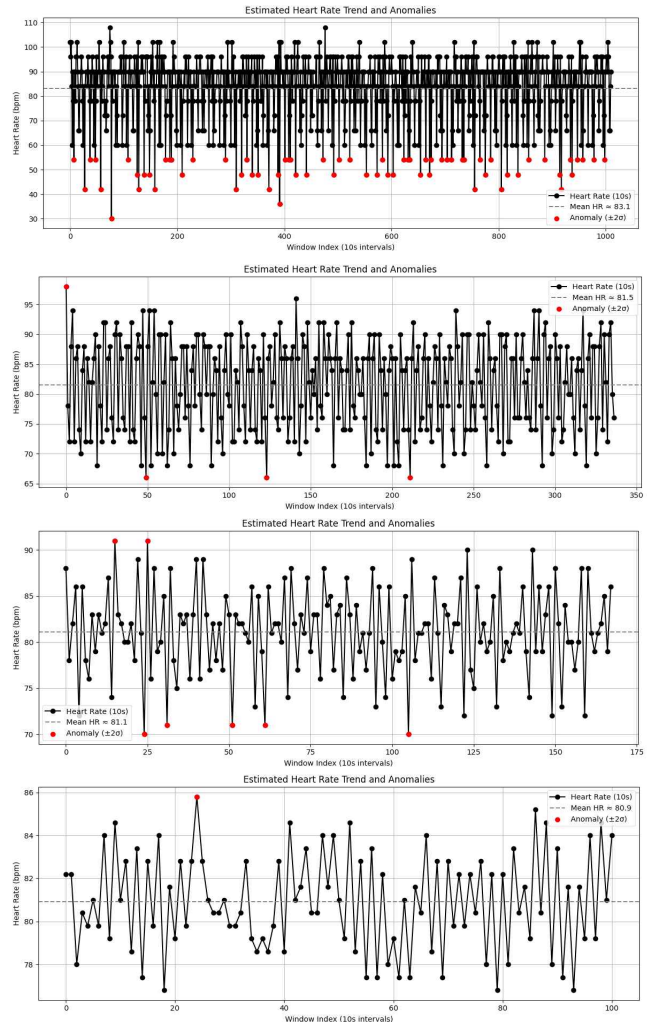


그림 2. 추정 BPM 및 이상 탐지 그래프

인하는 데 중요한 역할을 한다.

[그림 2]는 첫 번째 원시 신호에서 검출된 R-peak를 기반으로 계산된 10초, 30초, 60초, 100초 단위 평균 심박수(BPM)를 시각화한 것이다. 각 점은 해당 구간에서의 평균 심박수를 나타내며, 회색 점선은 전체 평균 심박수를, 빨간 점은 이상값을 나타낸다.

이 시각화를 통해 시간에 따른 심박 변화의 흐름을 확인할 수 있으며, 이상 구간이 시각적으로 강조되어 향후

건강 이상 탐지 또는 생체 신호 기반 알림 시스템 구현에 기초 자료로 활용할 수 있다.

[그림 1]과 [그림 2]의 그래프는 각각의 단위 및 목적이 다르지만, 서로 보완적으로 작용하며 신호의 품질 확인부터 건강 상태 요약에 이르기까지 심전도 데이터를 다양한 관점에서 해석할 수 있는 기반을 제공한다.

2.3. LSTM(Long Short-Term Memory) 모델 구성 및 학습

본 연구는 개인의 ECG 시계열 데이터를 입력으로 받아 다음 시점의 μV 값을 예측할 수 있도록 LSTM 모델을 구성하였다. LSTM은 시계열 데이터의 장기 의존성을 효과적으로 학습할 수 있는 순환신경망(RNN)의 한 변형 구조로, 생체 신호와 같이 패턴이 반복되고 시간에 따른 변화가 중요한 데이터에 적합하다.

표1. LSTM 하이퍼파라미터

Optimizer	Adam
Loss Function	Mean Squared Error (MSE)
Epochs	5
Batch Size	32

모델은 입력 계층, 단일 LSTM 계층, 출력 계층으로 구성되었으며 출력은 실수값 단일 노드를 사용하였고, [표 1]의 하이퍼파라미터를 바탕으로 총 5 epoch 동안 학습을 진행하였다.

III. 결 과

LSTM 모델은 시계열 데이터인 ECG의 미래 값을 예측하는 방식으로 학습되었다. 입력 데이터로는 일정 구간의 실제 ECG 파형이 주어졌고, 출력은 해당 구간 직후의 다음 시점 μV 값을 예측하도록 구성하였다.




그림 3. LSTM Train Loss 그래프

[그림 3]에서 볼 수 있듯이, 모델은 총 5 epoch 동안 학습을 진행했으며, 손실 값은 초기 4.2×10^{-3} 에서 최종적으로 2.6×10^{-5} 까지 점진적으로 감소했다. 이는 모델이 핵심 패턴을 신속하게 학습하여 손실 값이 0으로 수렴하고 있음을 명확하게 보여주며, 짧은 학습 횟수에도 불구하고 ECG 신호의 주기적 특성을 안정적으로 포착했음을 시사한다. 이러한 수렴은 모델이 과적합 없이 비교적 짧은 학습 시간 내에 ECG 파형의 전형적인 시계열 패턴을 효과적으로 학습하였음을 보여준다.

학습 및 테스트 후 모델의 성능을 시각적으로 확인하기 위해, [그림 4]와 같이 실제 파형(Actual)과 예측 파형(Predicted)을 동일한 시간 축 상에 겹쳐 표현하였다.

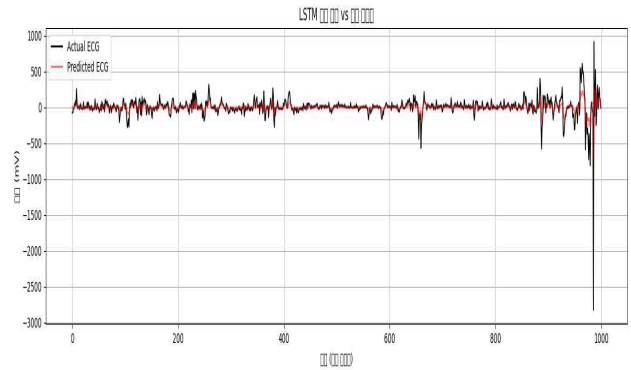


그림 4. LSTM ECG 파형 예측 그래프

약 1000개 샘플에 해당하는 구간을 기준으로 하였으며, 샘플링 주파수가 500Hz임을 고려하면 그래프는 약 2초 분량의 ECG 신호가 시각화된 것이라고 볼 수 있다. 시간 축은 샘플 인덱스 기준이며, μV 은 HiCardi 측정 기로부터 직접 수집된 ADC 값 단위로 표시되었다.

실제 파형의 900~1000 샘플 구간에서는 $-3000\mu V$ 수준까지 급격히 하강하는 진폭 변화가 관찰되었으며, 이는 장비의 흔들림, 피부 접촉 불량에 의한 잡음으로 해석된다. 예측 파형은 전체적으로 실제 파형의 흐름을 잘 따라가며, 특히 QRS 복합체가 존재하는 시점에서는 예측 신호와 실제 신호가 높은 일치도를 보였다. 그러나 잡음이 심하게 포함된 후반부 구간에서는 예측과 실제값 사이의 차이가 커지는 경향이 나타났다.

짧은 ECG 구간인 약 2초 분량을 예측 대상으로 삼았기 때문에 진단 목적에는 제한이 있으나, 본 실험은 LSTM 모델이 정상 심전도 신호의 주기성과 구조를 학습할 수 있는지를 확인하기 위한 기초 실험으로서 유의미한 결과를 도출하였다.

표2. LSTM 결과 해석

항목	결과 및 해석
epoch	5
최종 loss	2.6029e-06
손실 감소 양상	초반 빠른 감소 후 안정적인 수렴
과적합 여부	x (Train Loss 안정적)
오차 발생 구간	900~1000 구간에서 예측 정확도 급격 하락 → 외부 잡음에 의한 신호 왜곡
결론	적은 학습 횟수로도 정상 ECG 구조 효과적으로 학습

IV. 결 론

본 연구는 HiCardi 측정 기기를 통해 수집한 개인 ECG 데이터를 기반으로, 정상 심전도 파형의 시계열적 특성을 분석하고 딥러닝 기반 LSTM 모델을 통해 이를 학습할 수 있음을 실험적으로 확인하였다.

개인의 정상 상태 ECG 데이터를 사용하여 R-peak 기반의 심박수 추세 분석, 이상 구간 탐지, 그리고 LSTM을 통한 다음 시점 예측을 수행한 결과, 모델은 짧은 학습 시간에도 불구하고 손실 값이 2.6029e-05 수준으로 수렴하였고, 실제 파형과 예측 파형 간의 높은 일치도를 보였다.

이는 LSTM이 ECG의 반복적인 패턴, 특히 QRS 복합체 등을 효과적으로 학습할 수 있음을 시각적으로 확인한 결과이며, 정상 패턴을 학습한 모델이 이상 구간에서 예측에 실패하는 특성을 통해 향후 이상 탐지로 확장할 수 있는 가능성을 제시한다.

비록 본 연구는 한 사람의 데이터만을 바탕으로 진행되어 결과를 일반화하기에는 한계가 있지만, 정상적인 심전도 패턴을 인공지능이 학습할 수 있다는 가능성을 보여준 점에서 의미가 있다. 앞으로 더 많은 사람들의 심전도 데이터를 수집하고, 장시간 데이터를 분석할 수 있도록 모델을 확장한다면, 일상 속에서도 심장 건강을 꾸준히 확인할 수 있는 개인 맞춤형 모니터링 시스템으로 발전시킬 수 있을 것이다.

참고문헌

1. Pan, J. & Tompkins, W. J. A Real-Time QRS Detection Algorithm. *IEEE Transactions on Biomedical Engineering*, 32(3), 230-236 (1985).
2. Warrick, P. & Homsy, M. N. Cardiac Arrhythmia Detection from ECG Combining Convolutional and Long Short-Term Memory Networks, *arXiv:1801.10033*[cs.CV], 30 Jan 2018.
3. Nawaz, M. & Ahmed, J. Cloud-based healthcare framework for real-time anomaly detection and classification of 1-D ECG signals. *PLoS ONE* 17(12): e0279305 (2022).
4. Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer & François Lespinasse. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53, 1689-1696 (Aug 2021).
5. Guansong Pang, Chunhua Shen, Longbing Cao & Anton van den Hengel. Deep Learning for Anomaly Detection: A Review, *arXiv:2007.02500*[cs.LG], 6 Jul 2020.